T E C H N I C A L W H I T E P A P E R

汇智小助手技术路线报告

面向警务实战的智能体平台

系统名称：汇智小助手

文档类型：技术路线说明

文档版本：V1.1

发布日期：2026 年 10 月

目 录

注：本目录由域代码生成，编辑后如需页码准确，请右键目录选择「更新域」。

一、项目概述与技术定位.....1
1.1 建设背景.....1
1.2 技术定位.....2
1.3 与通用大模型对话的关键差异.....2
二、总体技术架构.....3
2.1 分层架构.....3
2.2 技术选型.....3
2.3 一次请求的完整链路.....4
三、底层技术实现.....5
3.1 智能体运行时.....5
3.2 推理循环与工具协调.....6
3.3 上下文管理机制.....6
3.4 流式输出与可靠性.....6
3.5 数据存储布局.....7
四、知识库构建流程.....7
4.1 全流程概览.....8
4.2 解析与降级策略.....8
4.3 多路检索与结果融合.....8
4.4 处理任务与失败重试.....9
4.5 知识图谱的多租户存储.....10
五、智能体与知识库的协同运转.....10
5.1 两种结合方式.....10
5.2 自动注入的工作细节.....11
5.3 数据分析：让不懂 SQL 的民警直接查数.....11
5.4 产出与交付.....12

5.5 典型协同流程.....13
5.6 会话的导入与导出.....13
六、多用户安全隔离与运行可靠性.....14
6.1 账号隔离的设计原则.....14
6.2 隔离的具体落实.....14
6.3 长期运行的稳定性.....15
6.4 部署形态.....16
七、结论与展望.....17
7.1 技术路线的本质.....17
7.2 已实现的业务价值.....17
7.3 模型资源的分配方式.....18
7.4 后续演进方向.....18
附录 关键技术参数速查.....19

一、项目概述与技术定位

1.1 建设背景

在传统警务信息化格局下，各类业务系统相互独立，数据分散在办案、话单、轨迹、资金等多个专业系统中。基层民警在使用这些数据时面临三重困难：一是系统之间彼此割裂，核查一条线索需要在多个系统间反复切换、人工比对；二是专业分析工具门槛高，多数民警不具备编写 SQL 或使用数据分析软件的能力，只能把少量数据导出到电子表格中做简单统计，难以支撑大数据量与多数据源的综合分析；三是数据之间的关联与规律隐藏在细节中，缺少自动化手段去发现。

本项目以通用智能体框架为基础做多用户化适配，构建面向警务实战场景的汇智小助手平台。平台的核心目标，是把原本需要逐个系统手工核查的流程，统一收敛为一次自然语言对话即可完成的协同核查，并在此基础上提供大数据量的关联分析与挖掘能力，从而显著提升民警的数据处理效率。

1.2 技术定位

平台在架构上定位为一个大模型驱动的多用户智能体平台，而不是一个传统的报表工具。其技术定位可以概括为四个层面：

- 会话层：以自然语言对话替代表单与查询语句，民警用日常语言描述需求即可，无需掌握关系数据库、图数据库知识。
- 知识层：将制度文件、案件材料、历史文书等非结构化资料构建为可语义检索的知识库，使模型回答有据可依。
- 数据层：把结构化的业务数据接入按账号隔离的数据库，再由案件（路径）二次划分范围，由模型理解表结构后生成只读查询，实现自然语言驱动的数据分析。
- 能力层：通过工具调用把文件处理、数据导入、图表生成、文档产出等具体动作交给程序执行，模型负责决策而非直接操作数据。

1.3 与通用大模型对话的关键差异

与直接使用通用大模型对话相比，本平台在工程上补齐了四项能力，这也是其能够进入实际业务场景的前提：

对比维度	通用大模型对话	本平台
数据来源	依赖模型训练数据，无法访问业务数据	接通账号隔离的数据库与知识库，回答基于真实数据
数据规模	模型上下文有限，无法处理大规模明细数据	由程序在数据库中完成聚合计算，模型只处理结论与结构
操作能力	仅能生成文本	可调用工具执行查询、导入、制表、编程、生成文档等动作
环境安全	公网服务，数据需外发	全内网离线部署，数据不出内网

表 1-1 本平台与通用大模型对话的能力差异

二、总体技术架构

2.1 分层架构

平台在部署上分为主应用与知识服务两个组成部分，均以容器方式运行，通过内网接口通信，并共用一个 PostgreSQL 实例。整体自上而下可分为五层：

层级	组成	主要职责
交互层	浏览器控制台（React 单页应用）	对话交互、会话管理、知识空间、数据分析、文件与技能管理、参数配置
网关与鉴权层	FastAPI 应用入口与认证中间件	令牌校验、账号识别、请求路由、公开路径放行控制
智能体运行时	运行时编排器、智能体构建器、执行器、工具协调器	按阶段编排一次请求，组装模型与工具，驱动推理与工具调用，输出流式事件
能力与数据层	文件、数据分析、知识检索、文档生成、代码编写等工具	把模型决策转化为对数据库、文件系统、外部服务的具体操作
存储层	PostgreSQL 数据库、LightRAG 图谱、工作区文件系统	知识数据、各账号分析库、会话完整轨迹、治理审计、用量统计、上传与生成的各类文件

表 2-1 平台分层架构

2.2 技术选型

平台的技术栈以成熟、可离线、长期可维护为原则选取，核心组件及版本如下：

层次	组件	版本/说明
运行时	Python	3.12
Web 框架	FastAPI + Uvicorn	异步接口与流式输出
智能体框架	AgentScope	2.0.4.post1，提供 ReAct 智能体与工具抽象
数据校验	Pydantic	2.x，全链路请求与状态模型

层次	组件	版本/说明
关系数据库	PostgreSQL	17，承载知识数据、平台数据（轨迹/审计/用量）与各账号分析库
向量检索	pgvector	向量列 + HNSW 索引，数据库内近邻检索
数据库驱动	psycopg / psycopg2	3.x（知识服务）/ psycopg2（主应用）
文档解析	MinerU	3.4.5，版面分析与公式表格识别
知识图谱	LightRAG	1.5.6，实体关系图谱检索，支持按案件划分工作区
前端	React + Ant Design + Vite	React 18 / AntD 5 / Vite 6
会话渲染	AgentScope Chat SDK	流式对话与卡片式工具渲染

表 2-2 核心技术选型

2.3 一次请求的完整链路

从民警在对话框输入问题，到页面显示回答，平台内部经过一条确定性的处理链路。这条链路的每一个环节都有对应的模块，便于定位问题与横向扩展：

- 第一步，请求进入。控制台以流式请求方式把消息发往主应用，鉴权中间件解析令牌得到账号身份，并把该身份注入请求上下文。
- 第二步，会话归位。系统按会话标识取出该会话的智能体与历史状态，新会话则自动创建并生成初始标题。
- 第三步，运行时编排。运行时按预派发、构建、执行、后置处理等阶段依次推进；构建阶段组装系统提示词、模型、工具集合与上下文管理组件。
- 第四步，知识注入。在模型推理前，系统按当前问题自动检索知识空间，把命中的资料片段作为背景信息注入本次推理。
- 第五步，模型推理与工具调用。模型决定是直接回答还是调用工具；若调用工具，由工具协调器负责执行、超时控制与结果回填，随后模型基于工具结果继续推理，直至得出结论。

· 第六步，流式回传。推理与工具调用过程中的事件被逐条翻译为前端可识别的消息，通过流式通道实时推送到页面，用户可以看到思考与执行的过程。

· 第七步，状态留存。会话状态、完整对话轨迹与用量统计被分别持久化到PostgreSQL，供刷新、重连与审计使用。

这条链路的关键设计在于：模型只负责决策与表达，所有涉及数据读取和文件操作的动作都通过受控工具执行。因此可以在工具层统一施加权限、路径与只读约束，而不必依赖模型自身的自觉。

三、底层技术实现

3.1 智能体运行时

运行时是平台的调度中枢，把一次请求拆解为可控的阶段序列，并在每个阶段对外开放扩展点。其设计要点有三：

- 阶段化编排。请求被划分为预派发、智能体构建、执行、响应后置等阶段，生命周期钩子可在指定阶段介入。账号身份注入、会话加载、状态保存等功能均以钩子形式实现，避免核心流程被业务细节污染。
- 构建与执行分离。构建阶段产出一个配置完整的智能体实例，执行阶段只负责驱动它运行。两者的分离使得同一个智能体可以被不同入口复用，也让构建结果易于缓存与诊断。
- 事件驱动输出。智能体运行过程中产生的事件被统一翻译为平台自己的消息格式，前端不需要理解模型框架的内部结构。这种隔离使模型框架升级不会波及前端。

3.2 推理循环与工具协调

智能体采用推理与行动交替的循环结构。每一轮循环中，系统先注入知识背景与待处理提示，再把当前上下文和可用工具清单提交给模型；模型若要求调用工具，则由工具协调器实际执行，并把执行结果作为新的输入交回模型，直到模型给出最终回答或达到迭代上限。

工具协调器统一承担四项职责：一是执行调度，支持同步与后台异步两种执行方式，耗时较长的操作可以转为后台任务，避免阻塞对话；二是超时控制，为每个工具配置独立的执行上限，并对长时间未完成的任务按比例设置卸载窗口；三是结果管理，工具输出有明确的大小限制，超限内容转为可追溯的引用而非直接塞入上下文；四是异常兜底，工具执行失败不会中断整轮对话，模型会收到失败信息并据此调整策略。

3.3 上下文管理机制

大模型的上下文窗口是有限的，而实际办案对话往往持续多轮、包含大量工具调用结果。平台采用滚动压缩策略解决这一矛盾，其核心思路是：完整历史永久保存，活跃上下文按需精简。

具体而言，系统在 PostgreSQL 中维护一份完整的对话轨迹库，逐条记录每个轮次的用户输入、模型输出、工具调用与结果。当活跃上下文接近模型窗口上限时，系统按语义优先级逐步压缩：先压缩较早且已完成的工具结果，把冗长的原始输出替换为可回溯的引用指针；仍不足时，再把中间轮次折叠为分层索引，仅保留最近一段原文以及当前正在处理的一轮。被压缩的内容不会丢失，模型在需要时可以通过历史回溯工具按索引重新取回原文。

这一机制带来两个直接好处：一是对话可以无限延续而不受窗口限制；二是刷新页面或重新打开历史会话时，能够从持久化轨迹中还原完整对话，而不只是窗口内的片段。

3.4 流式输出与可靠性

模型推理与工具执行耗时较长，若采用一次性返回，页面会长时间空白且容易被网络中断打断。平台采用流式输出并叠加多重可靠性措施：

机制	参数/策略	作用
传输层心跳	空闲 10 秒发送一次	保持连接，避免网关与浏览器判定超时
模型层心跳	空闲 25 秒发一次信号	长工具调用期间维持会话可用
首内容超时	默认 300 秒	自建模型的提示处理可能耗时数分钟，过短的超时会把「模型慢」误报为「产品故障」
稳态空闲超时	默认 300 秒	与首内容预算一致：生成开始后，重负载步骤同样可能长时间无输出
断线重连	按事件序号补发已产生内容	页面刷新或网络抖动后可衔接当前回答

机制	参数/策略	作用
增量检查点	每 2 秒保存会话状态	进程异常退出后仍可恢复部分内容
中断收尾	取消时补齐未完成的工具调用	避免留下悬空的调用记录

表 3-1 流式输出的可靠性设计

3.5 数据存储布局

平台的数据按其性质分工存储，避免单一存储承载全部职责。平台自身的运行数据与业务数据统一存放在数据库中：

- PostgreSQL 17：单一数据源，承载四类数据。一是知识库的结构化数据，包括知识空间、文档、分片、实体、关系与向量；二是平台自身的数据，包括会话完整轨迹、治理审计记录、用量统计与路径授权关系；三是各账号独立的数据分析库；四是知识图谱的图存储。
- 工作区文件系统：保存会话状态快照、上传文件、生成的文件与图表、以及各账号的暂存目录。目录结构按账号划分，实现文件层面的隔离。

把平台数据统一存放在数据库中的意义在于：备份与恢复只需针对一个数据源；数据不随容器重建而面临丢失风险；并且「谁在什么时候做了什么」这类记录可以和业务数据一样被统一查询与审计。

四、知识库构建流程

4.1 全流程概览

知识库的作用是把分散的制度、材料、文书转化为模型可以语义检索的知识。从民警上传一份文件到该文件可被检索，平台内部经过一条完整的处理流水线：

阶段	处理内容	关键设计
上传与校验	格式与大小校验，流式计算内容指纹	支持 PDF、Word、Excel、CSV、文本、Markdown、JSON 等；单文件上限 10 GB；重复文件按指纹秒级去重
落盘暂存	按知识空间与文档编号归档	文件落在知识空间目录下，与账号绑定
解析	版面分析与文本抽取	PDF 与 Word 优先使用 MinerU 进行版面、表格与公式识别；文本类文件走轻量解析
降级保障	解析失败时自动降级	MinerU 不可用或超时，自动回退为轻量解析，确保文档仍可入库
分块	按语义边界切分	以 1400 字符为基准，按中英文标点等边界切分，避免切断句子
向量化	调用向量模型生成语义向量	分批处理，每批 32 条，支持配置向量维度
实体与关系抽取	识别实体及其关联	由对话模型抽取，超长内容分批并并发处理；失败时使用人名启发式兜底
图谱入库	写入知识图谱	可选环节，LightRAG 可用时写入图谱，不可用时主流程不受影响
落库完成	写入结构化存储并建立索引	分片、向量、实体、关系分别入库，建立全文与语义索引

表 4-1 知识库构建流程

4.2 解析与降级策略

解析质量直接决定知识库的可用性。平台在解析环节采用主备双通道设计：

主通道使用 MinerU 进行深度解析，能够识别文档的版面结构、表格与数学公式输出带页码与位置的富结构片段。该通道依赖本地预置的模型权重，可完全离线运行。若解析命令不存在、依赖缺失、处于离线模式或解析超时，系统会自动切换到备用通道：Word 文档改用轻量库读取，PDF 改用文本抽取库处理。降级过程会记录日志并在文档记录中标注实际使用的解析后端，便于事后核查。

这种设计的意义在于，个别文件解析失败不会导致整批入库中断，民警的上传任务始终能得到明确结果。

4.3 多路检索与结果融合

单一检索方式难以覆盖警务材料的多样性：有的事项只写在文件名里，有的需要精确关键词匹配，有的只能靠语义相似发现。平台因此建立了多路并行检索机制，再对结果进行加权融合：

检索路径	实现方式	适用场景	置信权重
全文检索	数据库全文索引与相关度排序	正文中的术语、条款、表述	1.00
文件名匹配	按文件名做中文字符组合匹配	版本号、编号、年份等只写在文件名中的信息	0.95
关键词匹配	中文双字组合覆盖率打分	中文分词不理想时的字面命中	0.90
语义相似	向量近邻检索（数据库内完成，带向量索引）	表述不同但含义相近的查询；与语料规模无关	0.80
实体匹配	按实体名称关联相关分片	人名、地点、物品等实体的上下文	0.70
知识图谱	图谱路径检索	跨文档的多跳关联	预留配额

表 4-2 多路检索路径与权重

融合时，同一分片被多条路径命中的情况会合并其命中原因并取较高分值；命中来源越多，综合置信度越高。语义检索设置了相关性地板，低于阈值的语义结果会被丢弃，避免把语义上无关的内容当作证据送入模型，这一点对中文材料尤为重要。知识图谱结果按配额保留，仅在已有本地命中时补充，防止图谱噪声改变回答方向。

语义检索在数据库内完成：向量与其索引都存放在数据库中，由数据库执行近邻检索，应用只取回结果。因此检索延迟与内存占用都不随语料规模增长。

4.4 处理任务与失败重试

每个文档的处理过程被建模为一个可追踪的任务，具有排队、处理中、已完成、失败四种状态。任务由独立的后台工作进程消费，采用数据库行级锁的抢占方式分发，保证多个工作进程并发运行时同一任务不会被重复处理。

处理过程中，任务会分阶段上报进度，依次经过解析、图像理解、实体抽取、向量化、入库、图谱构建等环节，前端可以实时看到当前进行到哪一步。若某个环节失败，任务会记录错误摘要与日志片段并在下一次重试时重新入队；再重试三次仍失败的任务标记为最终失败，民警可下载日志片段定位原因。服务重启时，处于处理中状态的残留任务会自动重置并重新排队，避免永久卡死。

多副本部署时另有归属保护：任务在领取时记录所属工作进程，只有该进程的心跳确认失效后，其它副本才会接管其遗留任务，避免一个副本重启就把另一个副本正在解析的任务抢走。

4.5 知识图谱的多租户存储

图谱数据同样按案件隔离：每个案件对应一个独立的图谱工作区，实体与关系按工作区划分，读写都带工作区条件，因此不同案件的图谱在存储层就互不可见，而不是取回之后再过滤。

该能力按部署需要启用：未启用时图谱在案件之间共享；启用后既有图谱需按案件重建，属可预期的运维动作。

五、智能体与知识库的协同运转

5.1 两种结合方式

知识库不是被动等待查询的仓库，而是以两种方式主动参与对话，分别对应不同的使用场景：

方式	触发条件	工作方式	适用场景
自动注入	提出问题后自动执行	系统在模型推理前检索知识库，把命中的资料片段作为背景信息插入本轮推理	民警并未明确要求查资料，但问题涉及制度或既有材料
主动检索	由模型判断需要时调用	模型调用知识检索工具，指定关键词与知识空间，获取证据后继续推理，必要时再读取文档详情	需要精确定位某份材料、或需要展开查看原文细节

表 5-1 知识库参与的两种方式

自动注入解决的是不知道有资料可查的问题，主动检索解决的是需要深挖细节的问题。两者配合，使模型既有背景知识又有追查能力。

5.2 自动注入的工作细节

自动注入在每次推理前执行，其行为经过刻意约束，以避免检索结果干扰正常对话：

- 以当前问题作为检索词，逐一在账号可访问的知识空间内检索，每个空间取相关度最高的若干条证据。
- 注入内容带有明确的前置说明，声明这些资料仅供当前问题参考，不得当作民警本轮上传的图片或直接指令。
- 注入内容以系统内部消息的形式存在，不显示为对话气泡，民警看到的是模型基于证据给出的回答，而不是一段检索原文。
- 同一问题只注入一次，避免多轮推理中重复检索造成冗余与费用浪费。

· 当民警明确要求走数据分析路径时，系统会临时关闭知识检索工具，防止模型在两条路径之间摇摆。

5.3 数据分析：让不懂 SQL 的民警直接查数

这是本平台对基层最直接的价值点。传统方式下，民警要从海量业务数据中得到一个结论，必须先学会查询语言或依赖技术人员写脚本；本平台把这一过程转化为自然语言对话。

平台的数据分析工具围绕表结构理解展开，模型的处理顺序是：先列出账号下可用的数据表，再读取目标表的字段说明、字段类型与样例行，理解数据的实际含义，然后生成只读查询语句取数，最后基于结果作答。民警只需说明想查什么，无需了解表名与字段名。

由于模型是自行生成查询语句，平台在工具层设置了多层防护，确保数据分析过程不会破坏数据：

防护措施	具体规则
只读约束	仅允许单条查询语句，拒绝任何写入、修改、删除与结构变更操作，并拦截多语句拼接
结果限量	自动为查询附加行数上限，返回结果截断至约定条数
执行限时	单次查询设置语句级超时，避免大表全扫描长时间占用数据库
隔离双重	所有查询强制按所属账号过滤，并使用该账号独立的数据库；账号之内还可进一步限定到具体案件
结构自描述	字段以业务含义命名并带注释，使模型能准确理解字段用途

表 5-2 数据分析的安全防护

这一能力的实际效果，是把原本需要人工逐条核对、或在电子表格中反复筛选的统计工作，压缩为一次对话。对于需要跨多个数据源关联分析的任务，民警可以在同一会话中连续提出问题，由模型承担查询与关联的梳理工作。

5.4 产出与交付

分析结论不仅以文字呈现，平台还可以按需生成可直接使用的交付物，并通过对话内的文件卡片提供下载：

· 图表：将查询结果直接绘制为柱状图、折线图、饼图等，用于汇报与材料附图。

· 文档：把分析结论整理为结构化的 Word 文档，节省整理时间。

· 数据文件：把中间结果或明细导出为表格文件，供线下进一步使用。

这些产出文件与上传文件一样，保存在该账号自己的工作区内，其他账号无法访问。

5.5 典型协同流程

以一个实际核查任务为例，说明各环节如何衔接：民警在对话中描述需要核查的事项，系统自动检索知识库中相关制度与既有材料作为背景；模型判断需要调阅业务数据，于是调用数据分析工具，读取账号下的相关数据表结构并生成查询，取得统计与明细结果；若涉及跨源关联，模型继续发起第二轮查询，把不同来源的数据对齐比对；得到结论后，模型给出分析意见，并按民警要求生成图表或 Word 报告整个过程在对话中留痕，刷新页面后可以从完整轨迹中回溯每一步的查询与结论。

5.6 会话的导入与导出

会话本身可以作为一个文件被带走和放回：在会话列表中导出某次对话得到一个自包含的文件，在另一处导入即生成一次新会话。它解决两类场景：把培养好的问法沉淀下来交给同事复用；把某次分析过程完整归档或转移到另一台部署。

实现上有三条刻意的取舍：一是文件里不写入任何身份信息，导入时全部重新生成，因此无法用它冒充或覆盖他人名下的会话；二是导入永远是新建，同一文件导入两次得到两个互不相干的会话；三是正文与完整轨迹一并带走，导入后可以继续对话，而不是只留下只读记录。

会话也可以分享给其他账号归档，但必须经对方确认后才会复制到其名下，形成可追溯的分享链条。

六、多用户安全隔离与运行可靠性

6.1 账号隔离的设计原则

警务数据对隔离性要求极高。平台确立了三条不可妥协的原则：

- 身份必须可信且贯穿全程。账号身份在请求入口解析后注入整条执行链路，模型推理、工具执行、数据查询各环节都以同一身份为准，不接受前端自行声明的身份。
- 隔离在服务端强制执行。所有数据访问的账号过滤都在服务端完成，不依赖前端界面的隐藏或限制，即使绕过界面直接调用接口也无法越权。
- 失败时默认拒绝。当系统无法确定调用者身份时，相关操作直接拒绝，而不是退回到某个更高权限的默认身份。

6.2 隔离的具体落实

平台在账号隔离之内还设了一层：账号可以把自己的知识资料与数据表归入不同案件（路径），智能体只在被授权的案件范围内活动。这使得同一名民警名下、不同案件之间的材料也互不可见，而不只是民警之间互不可见。

资源类别	隔离方式
文件与目录	每个账号拥有独立的工作区根目录，所有文件读写操作在服务端校验路径必须落在本账号根目录内；目录名对中文账号名做哈希处理，避免路径问题并减少信息暴露
会话与消息	会话索引、会话状态与完整对话轨迹均按账号存放，查询时按账号过滤
知识空间与文档	知识空间与文档均绑定所属账号，并可进一步归入具体案件；服务端每次访问都校验归属。该隔离对管理员同样生效，管理员不通过此路径旁路查看他人资料
案件（路径）范围	账号内的案件是一层独立授权：资源可归入某个案件，智能体按案件授权活动，未授权案件的资料不会出现在检索与列表结果中

资源类别	隔离方式
数据分析库	每个账号一组独立的数据库对象，查询强制附加账号条件，并可按案件进一步限定
知识图谱	图谱按案件划分工作区，不同案件在存储层互不可见
工具权限	工具可见范围按账号配置，未授权的工具不会出现在模型可调用的清单中
暂存与中间产物	上传暂存、生成文件、图表等中间产物同样按账号分目录存放
统计与用量	词元与调用统计按账号归因，普通账号仅能查看自身的用量

表 6-1 各类资源的隔离方式

其中，工具权限的隔离值得单独说明。平台把每个账号可用的工具范围持久化为账号级配置，并在构建智能体时按此配置过滤工具清单。这样即使模型被诱导尝试调用某个工具，该工具也根本不在可供选择的列表中。

6.3 长期运行的稳定性

平台面向长期在线使用，因此在工程上针对持续运行做了专门处理：

- 资源占用可控。会话轨迹、重放缓存、上传暂存、日志文件等均有明确的保留期与容量上限，到期自动清理，避免长期运行导致磁盘与内存被逐步占满。
- 并发压力受控。对话模型调用设有全局并发上限，超出部分排队等待而非超时失败；数据分析查询设有语句级超时，防止单条大查询拖垮数据库。
- 同步操作分池隔离。文件读写、数据库访问、子进程调用与审计写入各自使用独立的线程池，互不挤占；任何池在等待预算内仍无法获得资源时，返回明确的错误而不是无限排队。
- 审计不占用主循环。治理审计的写入放在独立通道执行，即使审计通道繁忙也不会拖慢对话响应；审计失败会明确记录，不会静默丢失。
- 状态可恢复。服务重启后，未完成的知识处理任务会自动重新排队，对话状态可从增量检查点恢复，进行中的会话不会因重启而丢失。

· 异常有迹可循。各服务的运行日志、SQL 执行日志均落盘保存，便于事后定位问题；关键操作保留审计线索。

6.4 部署形态

平台采用容器化部署，分为主应用与知识服务两组容器，配合一个独立的 PostgreSQL 数据库容器。部署上做了三项针对性设计：

· 全内网离线运行。基础镜像预先内置依赖、解析模型与浏览器运行时，部署环境无需访问公网。

· 代码挂载式更新。底座镜像承载系统依赖，日常代码更新只需替换挂载目录并重启服务，不必重建镜像，显著缩短上线时间。

· 资源上限显式声明。各容器设置内存、CPU 与进程数上限，并按宿主机规格统一规划，防止单个容器占用全部资源影响其他服务。

此外，日志目录独立于数据目录挂载到宿主机，无论容器如何重建，日志都可在宿主机侧直接查看，为运维排查提供了稳定依据。升级包中随附升级与迁移说明文件，逐项写明哪些改动自动生效、哪些需要人工确认，避免依赖个人记忆。

七、结论与展望

7.1 技术路线的本质

回顾上述实现，本平台的技术路线可以概括为三句话：以自然语言为唯一入口，把专业门槛交还给系统；以知识库为事实依据，让回答有出处而非凭空生成；以受控工具为执行手段，让模型负责决策、程序负责动作。

其中最关键的是第三条。模型直接操作数据是不可控的，而把操作收敛为有限、可审计、带权限与路径约束的工具之后，模型的自由度恰好落在表达与推理层面，数据安全则由工程手段保证。这一分工正是平台能够进入实际业务场景的技术基础。

7.2 已实现的业务价值

- 核查流程统一化。原本分散在各专业系统中的逐项核查，收敛为一次对话内的协同核查，民警无需在多个系统之间切换与人工比对。
- 分析门槛大幅降低。民警无需掌握查询语言与数据分析工具，用日常语言即可完成大数据量、多数据源的综合分析，这是此前难以实现的能力。
- 知识沉淀可复用。历史材料与制度文件构建为可语义检索的知识库，经验积累不再依赖个人记忆。
- 产出一体化。分析结论可直接转化为图表与 Word 文档，减少二次整理工作。
- 数据安全有保障。账号与案件两级隔离，全内网离线部署，满足警务数据的管理要求。

7.3 模型资源的分配方式

平台不设置全局的「默认对话模型」。在多账号环境下，一个全局默认意味着某个账号可能在不经意间使用到并非为其开通的模型。平台改为按账号授权：在每个账号被允许使用的模型范围内自动选择一个作为起点，民警可以在授权范围内随时切换。这使模型资源的分配与账号权限保持一致，也便于按账号核算用量。

7.4 后续演进方向

在当前基础上，平台后续可从以下方向继续增强：

方向	内容	价值
数据源扩展	接入更多业务系统与外部数据源，扩大可协同核查的范围	进一步提升跨源关联分析的覆盖面
模型能力升级	支持更大参数规模与多模态模型，提升长文档与图像材料理解能力	改善复杂材料的解析质量
图谱深化	强化实体关系抽取与多跳推理，并在案件之间形成可控的关联视图	发现更深层的隐性关联
执行环境加固	在容器内启用系统级沙箱，对代码执行类能力实施更严格的资源与访问限制	进一步收紧残余风险
算力扩容	增加算力，提升多用户并发使用体验	支撑更大规模并发使用

表 7-1 后续演进方向

总体而言，本平台通过智能体技术与知识库能力的结合，为警务数据核查与分析提供了一条可行且安全的技术路径。其价值不仅在于把现有流程自动化，更在于让不具备技术背景的一线民警，第一次能够直接使用大数据分析能力，这是技术对实战能力的一次实质性增强。

附录 关键技术参数速查

表 A-1 平台关键技术参数

类别	参数	取值
模型推理	单次对话最大推理轮次	100 轮
模型推理	模型调用全局并发上限	6（生产配置，可按算力调整）
流式输出	传输层心跳间隔	10 秒
流式输出	模型层心跳间隔	25 秒
流式输出	首内容超时	300 秒
流式输出	稳态空闲超时	300 秒
流式输出	断线后重连可用窗口	10 分钟
上下文	压缩触发比例	窗口的 90%
上下文	触发时保留比例	窗口的 10%
上下文	会话轨迹保留期	30 天
上下文	工具结果单条上限（近期）	50 KB
上下文	工具结果单条上限（较早）	3 KB
知识库	支持文件格式	PDF / Word / Excel / CSV / TXT / MD / JSON
知识库	单文件大小上限	10 GB
知识库	聊天附件解析上限	50 MB
知识库	分块基准长度	1400 字符
知识库	向量化批处理大小	32 条/批
知识库	向量维度	1024
知识库	语义检索相关性地板	0.40
知识库	单次检索默认返回条数	20 条
知识库	自动注入资料条数上限	8 段，每段 900 字

类别	参数	取值
知识库	解析超时	900 秒（可配）
知识库	任务最大尝试次数	4 次（首次 + 3 次重试）
知识库	失败任务重试间隔	1 小时
数据分析	查询语句超时	30 秒
数据分析	结果返回行数上限	100 行
会话管理	状态增量检查点间隔	2 秒
会话管理	导出文件格式	自包含 JSON（不含身份信息）
并发控制	同步 IO 线程池	按用途分池：数据库/文件/子进程/审计
并发控制	池满时的行为	有界等待后返回明确错误，不无限排队

说明：上表参数与当前部署的出厂配置一致，可按实际服务器规格调整；涉及模型并发与超时的参数调整需同时评估算力与网络状况。